

基于昇腾的大模型 推理引擎优化实践



目录

- 1 分布式集群推理的背景和挑战
- 2 FlashOverlap
——计算通信重叠新探索
- 3 Semi-PD
——PD分离新探索
- 4 昇腾芯片上的优化和工程实践

目录

1 分布式集群推理的背景和挑战

2 FlashOverlap
——计算通信重叠新探索

3 Semi-PD
——PD分离新探索

4 昇腾芯片上的优化和工程实践

尺度定律(Scaling Law)逐步转向推理规模扩展

国外标志性节点

Google

Google

OpenAI

OpenAI

ChatGPT

Meta

OpenAI

OpenAI

2017年谷歌提出Transformer

Transformer架构奠定了LLM基础，开启大模型时代

2019年谷歌提出T5架构

验证"Text-to-Text"范式在NLP任务中的通用性

2020年OpenAI提出GPT-3

展示LLM强大的少样本学习能力，引发业界对大模型的研究热潮

2022年OpenAI提出InstructGPT

提出利用RLHF讲LLM与人类对齐，ChatGPT的基础

2023年OpenAI ChatGPT爆发

引爆全球生成式AI应用，标志AI进入大规模普及阶段

2023年Meta开源Llama

后续逐步成为全球第一大大模型开源模型及生态

2024年OpenAI SORA爆发

火爆全球的视频生成软件，首次实现1分钟长视频的生成，且画面一致性较高

2024年OpenAI 提出O1系列模型

将长思维链推理技术带入主流，总结Test Time Scaling，显著提升模型的推理能力

国内标志性节点

2017

sensetime

MEGVII 旷视

2016年商汤、旷世崛起

以计算机视觉技术为核心，推动AI在安防等领域的落地

2019

Baidu 百度

2021年百度推出ERNIE-3.0

在多项NLP任务中超越GPT-3

2020

2021

清华大学
Tsinghua University
智谱·AI

智谱推出ChatGLM

第一个国产大模型

ChatGLM

2022

2023

Qwen

阿里通义千问开源

后续逐步成为继Meta Llama之后的全球第二大大模型开源模型及生态

2024

清华大学
Tsinghua University
生数
ShengShu

2024年生数推出ViDU

生数科技发布国内首个文生视频模型，距离Sora发布仅2个月

字节跳动

百模大战

国内多家公司相继发布自研大模型，API服务价格降低10倍以上


2025

DeepSeek R1-Zero

2025年DeepSeek开源R1推理模型

比肩OpenAI O1算法性能的同时，成本仅为5%~10%

尺度定律(Scaling Law)逐步转向推理规模扩展



Ref: NVIDIA CEO Jensen Huang Keynote at CES 2025

Deepseek等模型推动应用落地加速，带来推理需求爆发

预训练时代即将结束




Pre-training as we know it will end


Compute is growing:
- Better hardware
- Better algorithms
- Larger clusters
Data is not growing:
- We have but one internet
- The fossil fuel of AI

Ilya, NeurIPS 2024


步入2025年，受限于预训练数据、大模型迭代周期、硬件成本等因素



Pre-Training Scaling
收益正在衰减



单位: 万



Ref: QuestMobile A 产业洞察研究院 2025年1月

推理算力需求“喷发式增长”



黄仁勋, GTC 2025

为了保持模型的响应速度，让用户不会因等待而失去耐心，我们现在需要将计算速度提高10倍，黄仁勋表示：

整体计算需求
轻松增长至100倍

推理模型需要在回答之前进行多轮内部推理，因此计算需求大得多，响应时间也更长。

🔥 LLM基础概念：Prefill和Decode



大语言模型

input = "用python实现
冒泡排序"

输入的prompt

↓ Prefill阶段

output = "def"

第1个token

↓ Decode阶段

output = "def bubble"

第2个token

↓ Decode阶段


output = "def bubble_"

第3个token

.....

Prefill
阶段

Decode
阶段



推理流派：从PD融合到PD分离



大语言模型

input = "用python实现冒泡排序"

输入的prompt

↓ Prefill阶段

output = "def"

第1个token

↓ Decode阶段

output = "def bubble"

第2个token


↓ Decode阶段

output = "def bubble_"

第3个token


.....

PD融合式推理



请求的Prefill和Decode阶段均在相同实例进行计算和存储

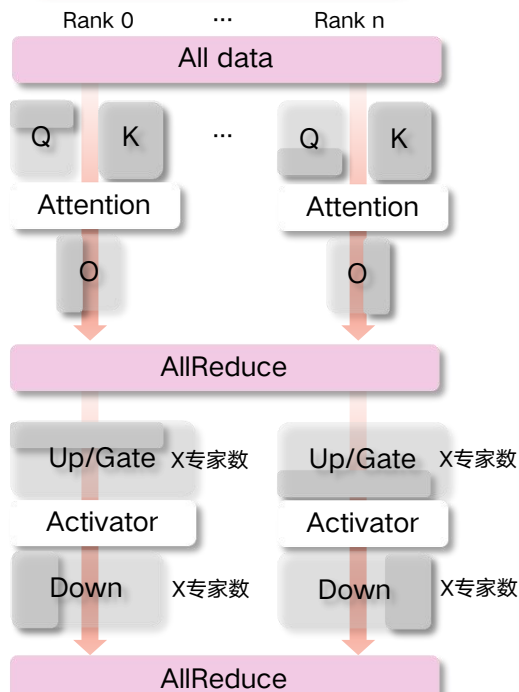
PD分离式推理



请求在Prefill实例上完成Prefill阶段后，传输KV cache至Decode实例进行计算

并行策略：从TP到DP+EP

TP



DeepSeek-671B 模型特征

**特征1: Attention KVcache
维度为MQA模式无法切分并行**

TP: 不同rank计算存储相同数据,
显存浪费

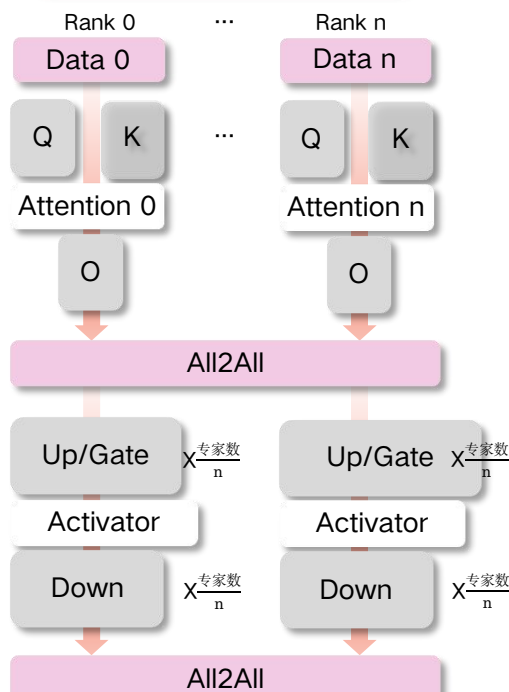
DP: 不同rank计算存储不同数据,
可用显存提高20+倍

**特征2: FFN 隐藏特征
维度过小, 切分并行度受限**

TP: 最大并行度约32, 且并行度增加导致
计算效率下降

EP: 最大并行度256, 且计算效率与并行度
正相关, 可扩展性提高至少一个数量级

DP + EP



分布式集群推理仍然存在诸多挑战

分布式集群推理挑战

并行引入大量通信开销

并行模式	通信模式	通信开销
张量并行 (推理)	AllReduce	10-30%
张量并行 (训练)	ReduceScatter	10-40%
专家并行 (推理/训练)	All2All	10-40%

PD分离/PD融合
存储和计算效率难兼顾

PD	计算效率	存储效率
PD融合	✗ P/D延迟干扰严重	✓ 无存储冗余和传输开销
PD分离	✓ P/D隔离计算无延时干扰	✗ 权重存储冗余, 传输开销

国产芯片集群推理适配
优化难, 滞后严重

	英伟达	昇腾
	SIMT众核架构 较好通用性	SIMD架构 数据通路专用, 通用性弱
	CUDA+Triton+CUTLASS 推理性能和开发效率	AscendC 需要熟悉硬件细节, 开发难度大
	NCCL+NVSHMEM+社区 (DeepSeek的all2all通信库) 通信库支持较好	主要依赖HCCL
	vLLM/SGlang/NVIDIA Dynamo 社区框架, 功能性能俱佳	阿墨/mindIE/vLLM-Ascend 分布式推理需后NVIDIA

2

FlashOverlap计算通信
重叠新探索

3

PD分离新探索

4

分布式集群推理在昇腾
上的实践

目录

1 分布式集群推理的背景和挑战


2 FlashOverlap
——计算通信重叠新探索

3 Semi-PD
——PD分离新探索


4 昇腾芯片上的优化和工程实践

大模型推理/训练中通信开销不可忽略

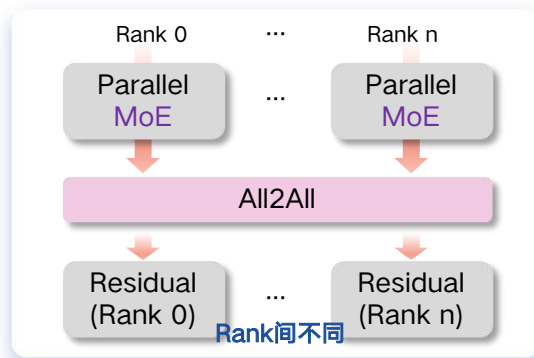
张量并行（推理）



张量并行（训练）




专家并行（推理/训练）



挑战：通信与计算存在数据依赖，故阻塞计算，影响端到端效率


并行模式	通信模式	典型通信开销
张量并行（推理）	AllReduce	10-30%
张量并行（训练）	ReduceScatter	10-40%
专家并行（推理/训练）	All2All	10-40%

GEMM和通信操作重叠相关工作




1) 基于张量分解的计算通信重叠方法

- 重叠粒度: 重叠粒度大, 计算算子数增多
- 计算干扰: 限制按M维度切分, 计算效率下降
- 通信感知: 不感知通信, 无缝兼容各种通信算子




方法	细粒度重叠	计算无干扰	通信无感知
张量分解	×	×	✓
算子融合			

GEMM和通信操作重叠相关工作




2) 基于算子融合的计算通信重叠方法

- **重叠粒度**: 重叠粒度小, 计算算子不被一分为多
- **计算干扰**: 限制按M维度切分, **计算效率下降**
- **通信感知**: **通信兼容性差**, 需要手工实现不同通信代码



方法	细粒度重叠	计算无干扰	通信无感知
张量分解	✗	✗	✓
算子融合	✓	✗	✗


GEMM和通信操作重叠相关工作



因此，我们认为低开发成本高性能收益的计算和通信重叠方案，需要满足三个方面


方法	细粒度重叠	计算无干扰	通信无感知
张量分解	✗	✗	✓
算子融合	✓	✗	✗
?	✓	✓	✓

FlashOverlap——基于信号的计算通信重叠




Timeline


FlashOverlap——基于信号的计算通信重叠




FlashOverlap——基于信号的计算通信重叠



FlashOverlap——基于信号的计算通信重叠




FlashOverlap——基于信号的计算通信重叠



计算通信重叠效果

Primitive	AllReduce		ReduceScatter		All-to-All
	A800	4090	A800	4090	A800
$M \times N (\times 1024^2)$	64~256	16~64	64~256	16~64	8~48
$K (\times 1024)$	4~8	8~16	4~8	8~16	4~8



FlashOverlap可以获得1.07-1.7X性能提升，而且大多数情况下都优于其他SOTA工作

目录

- 1 分布式集群推理的背景和挑战
- 2 FlashOverlap
——计算通信重叠新探索
- 3 Semi-PD
——PD分离新探索
- 4 昇腾芯片上的优化和工程实践

大模型集群推理挑战

① 计算挑战

Prefill阶段
计算密集型

Decode阶段
访存密集型

input = "用python实现
冒泡排序"
输入的prompt

↓ Prefill

output = "def"

第1个token

↓ Decode

output = "def bubble"

第2个token

↓ Decode

output = "def bubble_"

第3个token

.....


算子	Prefill计算 访存比	Decode计算 访存比
$Q/K/V$ $/O$	$\frac{ld}{l+d}$	$\frac{d}{d+1}$
QK^T	$l < 1$	$\frac{l}{l+1}$
AttenV	l	$\frac{l}{l+1}$
FFN	$\frac{ld_{FFN}}{l+d_{FFN}}$	$\frac{d_{FFN}}{d_{FFN}+1}$

Prefill和Decode两阶段计算特性不同
需分别针对性优化计算


② 存储挑战

云侧集群
存储容量大

推理服务
存储利用率低



集群存储
TB量级




请求不等长
存储碎片造成利
用率低 (~70%)

请求动态生成引入存储碎片
导致系统存储利用率低

③ 调度挑战

用户需求
低延时

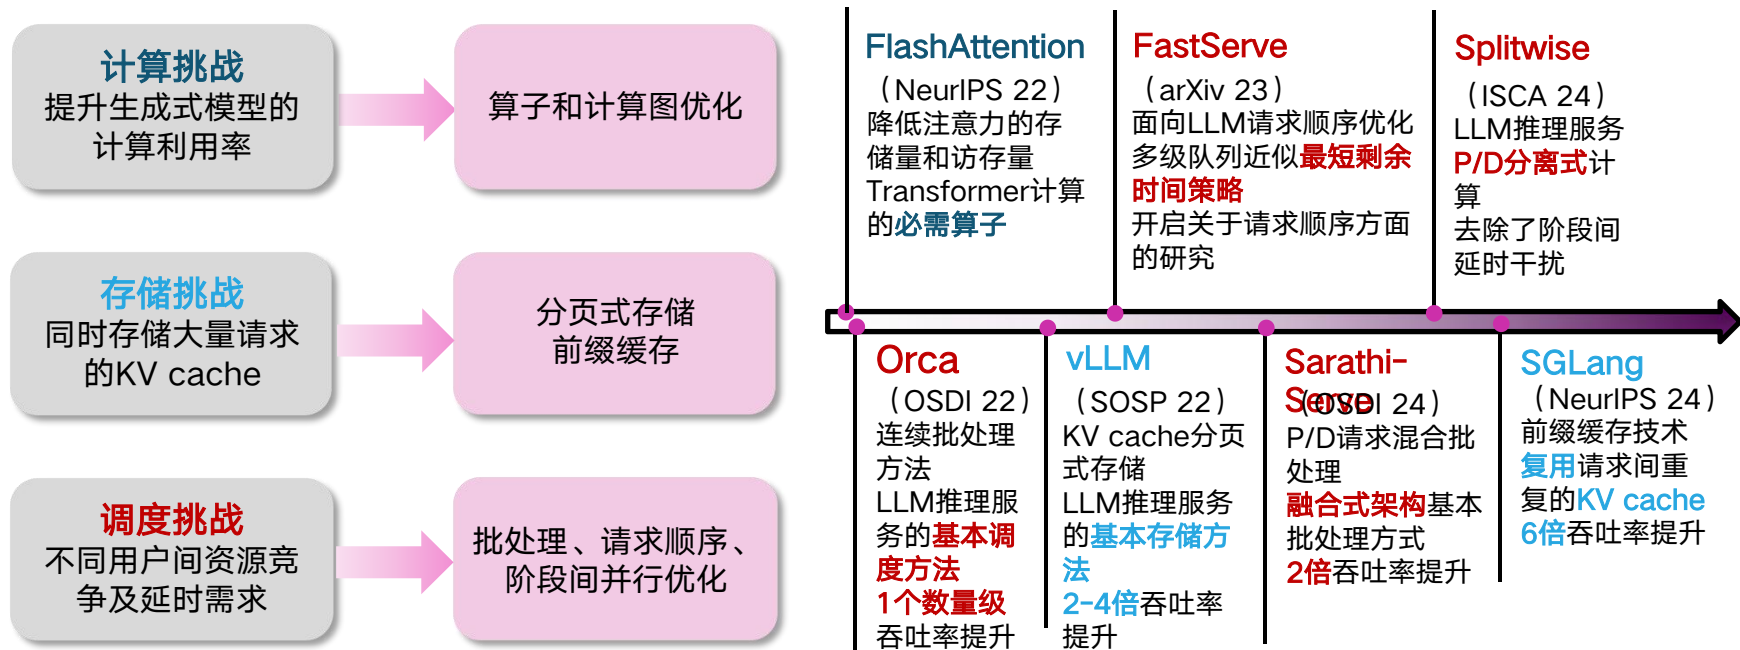
系统需求
高吞吐率



用户间存在资源竞争
在满足用户目标前提下提升系统吞吐率

大模型集群推理核心技术相关工作


集群推理服务：多用户、多请求




云侧推理服务技术Milestone

融合式与分离式实例背景

融合式实例：P/D计算和存储共享资源



分离式实例：P/D计算和存储资源分离



代表
框架



- [1] W. Kwon, et al. "Efficient Memory Management for Large Language Model Serving with PagedAttention.", SOS, 2023.
[2] L. Zheng, et al. "SGLang: Efficient Execution of Structured Language Model Programs", NeurIPS, 2024.



代表
框架



- [3] DeepSeek-AI. "DeepSeek-V3 Technique Report", arXiv, 2025.
[4] R. Qin, et al. "Mooncake: Trading More Storage for Less Computation", FAST, 2025.

融合式与分离式实例分析

融合式实例：P/D计算和存储共享资源



计算
劣势

P/D间请求延时干扰严重

P/D计算资源配比不可控

存储
优势

P/D计算之间无需传递KV cache

KV cache能使用所有存储资源

代表
框架




[1] W. Kwon, et al. "Efficient Memory Management for Large Language Model Serving with PagedAttention.", SOSPP, 2023.

[2] L. Zheng, et al. "SGLang: Efficient Execution of Structured Language Model Programs", NeurIPS, 2024.

融合式与分离式实例分析

计算
优势

P/D隔离计算无延时干扰
可以通过GPU数配比计算资源




存储
劣势

P/D实例间KV cache存储不均衡
(例, P: 23% v.s. D: 72%*)

资源调整涉及存储搬移开销

分离式实例：P/D计算和存储资源分离



代表
框架



Mooncake



deepseek

*Llama3-70B, Prefill实例TP=4, Decode实例TP=4, ShareGPT数据集

[3] DeepSeek-AI. "DeepSeek-V3 Technique Report", arXiv, 2025.

[4] R. Qin, et al. "Mooncake: Trading More Storage for Less Computation", FAST, 2025.

融合式与分离式实例分析

融合式实例：P/D计算和存储共享资源

计算
劣势

P/D间请求延时干扰严重

P/D计算资源配比不可控

存储
优势

P/D计算之间**无需传递KV cache** ✓

KV cache能使用**所有存储资源**

分离式实例：P/D计算和存储资源分离

计算
优势

P/D隔离计算**无延时干扰** ✓

可以通过GPU数**配比计算资源**


存储
劣势

P/D实例间KV cache存储不均衡
(例, P: 23% v.s. D: 72%*)

资源调整涉及存储搬移开销

🔗 Semi-PD——计算分离存储融合实例

计算分离 & 存储融合：P/D计算资源隔离，但是共享存储资源



单个semi-PD实例

P/D计算资源隔离且分为不同数据流

但是共享相同的存储资源

计算优势

P/D隔离计算无延时干扰

可以通过GPU数配比计算资源

P/D计算之间无需传递KV cache


KV cache能使用所有存储资源

存储优势

🌀 Semi-PD——计算分离存储融合实例


技术细节：计算分离 & 存储融合

计算
分离



P/D阶段的计算分别由不同的进程（抽象为worker）完成
进程间实现**SM粒度的计算资源划分**

存储
融合




通过**原子化的显存分配**避免P/D worker显存管理的冲突

技术细节：低开销资源调整机制


挑战

P/D间资源调整模型权重重载、KV cache拷贝开销，造成请求阻塞

优化前



优化后




方案

引入**常驻进程管理**模型权重和KV cache**存储**，无需重载和拷贝

🔥 Semi-PD——计算分离存储融合实例

实例推理场景


每张GPU上的P/D worker独立、异步地与并行组进行通信，通信总量不变



*以TP=2, PP=2为例

集群推理场景

semi-PD实例作为**可选实例之一**，与P/D实例
共同参与请求路由




计算分离存储融合效果

semi-PD+SGLang结果
SGLang结果

测试配置
DeepSeek-V3模型
FP8, TP8
输入均值2k, 输出均值256

同时取得10%的吞吐率提升
和2倍的延时降低



目录

- 1 分布式集群推理的背景和挑战
- 2 FlashOverlap
——计算通信重叠新探索
- 3 Semi-PD
——PD分离新探索
- 4 昇腾芯片上的优化和工程实践

昇腾&英伟达相关软件栈对比



	英伟达	昇腾
体系结构	SIMT众核架构 较好通用性	SIMD架构 数据通路专用，通用性弱
编程	CUDA+Triton+CUTLASS 兼顾性能和开发效率	CANN+Triton+CATLASS 需要熟悉硬件细节，开发难度大
通信	NCCL+NVSHMEM+社区 (如DeepEP)	主要依赖HCCL
LLM Serving	vLLM/SGLang/Dynamo 社区繁荣，功能性能俱佳	MindIE/vLLM-Ascend/ Omni-infer 分布式推理落后NVIDIA

我们的探索


- ① GEMM算子深度优化
- ② FlashOverlap深度适配优化
- ③ 面向昇腾集群的推理框架实践

groupGEMM优化


- 异构任务映射充分利用AIC计算核心和AIV计算核心
- 负载均衡和自适应策略：根据任务的规模自适应调整
- groupGEMM算子相比acINN优化性能提升高达1.8倍



■ acl nn ■ i n f i n i — speedup





■ acl nn ■ i nf i ni — speedup




二、FlashOverlap在昇腾上的高效优化适配

基于AscendC得信号机制


- ❑ 计算Kernel采用昇腾团队提供的算子模板库
- ❑ 通信直接使用HCCL通信库
- ❑ 先后尝试3种信号方案，给昇腾同事提了5+ bug issue和不符合预期行为，双方深入技术交流
- ❑ FlashOverlap在昇腾上，GEMM+AllReduce性能相比acINN+HCCL提升高达35%



GEMM+AllReduce 算子时间对比 [M=2048]



三、基于昇腾芯片的分布式集群推理方案



云原生

- 弹性扩缩容
- 根据负载及前缀匹配程度智能路由

运行时

- 层级别混合并行，DP、EP、SP
- 计算 & 通信优化
- 长文本优化

KV Cache

- 非阻塞流式传输，层间算传并行
- 多级KVCache分布式缓存

Thanks

