


强化学习RL关键加速技术和训练实践

潘晨毅 昇腾计算强化学习专家

- > 强化学习训练系统面临的主要挑战
- > 强化学习训练关键加速技术和MoE训练加速
- > MindSpeed RL及R1复现实践

强化学习面临“训练+推理”所带来的系统级挑战

AS IS：传统全参/低参微调



TO BE：强化学习后训练




强化学习面临的挑战


- > **异构多模型协同部署策略**
复合AI系统中不同模型尺寸及结构不同，不当的并置/分离策略可能引入模型级空泡，导致NPU利用率低
- > **模型并行及调度策略寻优**
多个异构大模型同时训练/推理，训推各自最优的部署策略不尽相同
- > **训推混部与训推转换**
训推共卡部署需要频繁的训推并行策略转换；训推分离部署涉及高效参数同步通信，同时引入模型级别空泡
- > **长序列、数据异构导致负载不均**
不同问题的CoT生成Token数差异大，形成长尾空泡。同时，序列长度增加，造成推理时间及成本增大。
- > **Self-Play推理速度成为系统瓶颈**
R1训练长思维链推理token数多，最长序列往往推理到限制token数，导致推理速度成为系统瓶颈。

训推共卡，并行策略在线切换，使能高效训练推理

训推共卡，节省计算资源**50%**，每卡吞吐提升**1X**



支持训推最优并行策略权重的TP/PP/EP重切分




Step1: TP/PP/EP成倍缩小

Step2: TP/EP成倍扩大

训推切换0冗余内存调度，推理可用内存提升**80%**


精细化内存管理，内存高效的RL训练



训推切换过程模型权重、优化器状态、梯度内存精细管理，提升推理可用内存，使能Reasoner长序列训推

调度优化：灵活高并发的流式数据引擎，端到端吞吐提升10%+


Post-Training算法数据流复杂



Actor推理生成训练语料 各模型串行前向生成语料打分 模型根据生成语料进行多轮训练

异步ReplayBuffer: 数据流式管理，任务流水掩盖

RL训练数据流存在细粒度可掩盖空泡




特点

- ① 效率提升：解耦数据依赖，使能异步训练与任务流水掩盖
- ② 负载均衡：训练数据全局管理，各实例按需取用，能者多劳
- ③ 范式简化：统一数据入口，无需绑定数据生产消费链路

实现后训练数据的全局流式高效搬移，提高计算任务效率


千亿规模MoE性能优化，RL高性能的训推部署和加速

极致MoE训练加速：PP流水掩盖&内存优化



采用改进的Cut-in-half流水调度+昇腾亲和前反向掩盖，结合细粒度Swap与重计算

Virtual Optimizer



峰值内存 降低80%

通信占比 降至12%

训练效率 提升20%


将优化器内存全部卸载到Host内存，通过流式内存版本使能Device侧高性能AdamW融合算子

极致MoE推理加速：RL亲和的大EP推理

推理：专家EP64 AttTP4

vLLM

机内专家的部署策略




PD混部，推理共享专家副本+基于负载热点专家的冗余专家动态调度

MindSpeed RL: MindSpeed + vLLM的工业级高性能RL框架


SPMD+MPMD编程范式，算法友好

```
1 with Timer(name='iteration', logger=None) as all_timer:
2     # generate sequences
3     self.actor_worker.generate_sequences(blocking=self.blocking)
4     # compute rm scores.
5     for reward_worker in self.reward_list:
6         if isinstance(reward_worker, RayActorGroup):
7             reward_worker.compute_rm_score(blocking=self.blocking)
8         else:
9             self.rule_reward_compute_rm_score(reward_worker, blocking=False)
10
11     # compute advantages, executed on the driver process
12     self.compute_advantage(blocking=False)
13
14     # compute reference log_prob
15     self.ref_worker.compute_ref_log_prob(blocking=self.blocking)
16
17     # compute old log_prob
18     self.actor_worker.compute_log_prob(blocking=self.blocking)
19
20     self.actor_worker.wait_all_ref_objs_run_over()
21     self.ref_worker.wait_all_ref_objs_run_over()
22     for reward in self.reward_list:
23         if hasattr(reward, 'wait_all_ref_objs_run_over'):
24             reward.wait_all_ref_objs_run_over()
```


高性能RL: MindSpeed LLM + vLLM的训推后端



数据面控制面分离




模块分层解耦，易于二次开发




基于昇腾MindSpeed RL复现R1-Zero实践

同参数配置下，千步长稳精度、下游评分对齐业界标杆RL框架（Qwen2.5-32B-Base + MindSpeed RL）



复现R1-Zero，评测集得分对标业界，性能持续引领

Model	MATH 500 (Pass@1)	AIME24 (Avg@32)	GPQA Diamond (Avg@32)
Qwen-2.5-32B	68.6	4.5	32.1
Qwen-2.5-32B+业界RL	82.4	27.2	-
Qwen-2.5-32B+MindSpeed RL	83.2	30.4	41.1



Thanks

